


Интерпретируемость – это область изучения искусственного интеллекта, где мы пытаемся понять, как работают нейронные сети, которые мы пиши, какие абстрактные концепты они выучивают и как оперируют ими. Актуальность таких работ подается через понимание того, какими признаками пользуется модель, похожи ли они на то, что мы ожидаем или мы выучили просто случайные корреляции; на каких данных нейронная сеть может ошибаться и почему; как модель можно дальше улучшить, обобщить или уменьшить по занимаемой памяти и времени инференса. Все эти работы часто изучают уже итоговую обученную модель, не обращая внимания на сам процесс трейна и к какому оптимальному решению с точки зрения геометрии лосса модель пришла.

Singular Learning Theory (SLT) предлагает подход под названием *developmental interpretability*, где нейронная сеть рассматривается как байесовский объект, который в течение обучения претерпевает обновление параметров, и мы наблюдаем за вырожденностью решения в каждый момент времени. За это отвечает величина Local Learning Coefficient (LLC), которая описывает эффективное число параметров в локальной окрестности функции потерь нашей модели (или же по-другому, сингулярность гессиана). Меньше ее значение, меньше эффективных параметров, проще решение, выше способность к генерализации; примерно таким рассуждениям следует теория.

Статья, которую я решил изучить – [Differentiation and Specialization of Attention Heads via the Refined Local Learning Coefficient](#). Авторы, используя алгоритм для эмпирической оценки LLC через динамику Ланжевена, показывают применимость этой величины для интерпретации голов маленькой нейросети, состоящей из двух слоев внимания. В своем главном эксперименте они находят, что головы разделяются по функционалу на индукционные и работающие с мультиграммами, и это можно определить при помощи LLC. Эта величина работает как в динамике, кластеризуя схожие по функционалу головы по временным рядам изменения LLC с шагом обучения, так и в статике, когда в каждый момент времени более простые головы (индукционные) имеют меньшие значения LLC, то есть меньшее число эффективных параметров, а более сложные головы (запоминающие мультиграммы) – большие значения, больше эффективных параметров.



Из сильных сторон статьи можно найти очень строгую математическую основу. Вся теория вокруг выстроена на байесовском обучении и аналогии со статистической физикой, что добавляет интуиции использованию одного параметра, который описывает сложную систему из многих переменных (как энергия или давление газа являются собирательными величинами микроскопических параметров его частиц). Также авторы имеют очень четкую методологию,

валидируя каждый сделанный шаг, даже кластеризацию проводят многими способами и с разными метриками, чтобы получить наиболее непредвзятое представление о системе.

Из минусов статьи можно отметить слишком сильную модельность – нейронная сеть из двух слоев внимания – это важный объект, но сильно неактуальный относительно величин нынешних нейронных сетей, поэтому возникают вопросы с тем, насколько это решение может масштабироваться. Также свойства самой эмпирической оценки не сильно понятны, мы не знаем, насколько она *biased* и какой у нее разброс, а сам результат вычисления зависит от выбранных параметров динамики Ланжевена. Однако утверждается, что хотя бы одно из главных свойств выполнено – если истинное значение LLC для первого набора весов меньше, чем для второго, то это же верно и для оценок, поэтому как минимум для сравнения голов между собой такой подход можно использовать.

Мне стало интересно, как соотносятся результаты SLT с более классическим подходом из механистической интерпретируемости для определения причинности связей. Для этого брались примеры, в которых должны активироваться индукционные головы (повторить пример последовательности слева [A][B] [A] -> [B]) или мультиграммные головы, считался лосс предсказания на них, а затем рассматривались ситуации, в которых выход каждой из голов поочередно выставлялся равным 0. Разница в лоссе отражала *causal* эффект головы для каждой из задач. Код можно найти в репозитории <https://github.com/ssslakter/tool-call-eval/tree/main/2026>.

Результаты показывают, что по крайней мере некоторые из функционалов голов имеют сильный казуальный эффект, когда же большинство скорее нет. Это можно связать либо с таргетностью моего синтетического датасета (например, для мультиграмм использовался конкретный небольшой список вопросов), тогда головы 1:1-1:5 просто отвечают за другой список мультиграмм, который я не провалидировал; либо же с тем, что LLC определяет не казуальные взаимоотношения, а возможно, *spurious* корреляции, например, если голова была названа индукционной на каком-то сете примеров, где везде использовались слова со схожей семантикой, что было таргетом этой на самом деле мультиграммной головы (это могло бы объяснить поведение 1:7)

Дальнейшие исследования в области SLT должны быть направлены на более реалистичные кейсы, а также новизну результатов, которые невозможно получить, не рассматривая динамику обучения

